

Von arbeitsrechtlichen Unterlagen zum verifizierten Fall

Wie ARAM die Verlässlichkeit von Intake prüft: unabhängig,
Schritt für Schritt und so, dass jeder Fehler erklärbar wird.

Woher wissen wir, dass Intake richtig arbeitet, wenn die Beweislage
vollständig, lückenhaft, mehrdeutig oder widersprüchlich ist?

Baseline **golden-2026-09-25**

Datensatz **TAURI-DE-GOLDEN-40**

Bewertete Jobs **240**

Testfälle **40**



Geschrieben für vier Fragen

HR / PERSONALABTEILUNG

„Kann ich mich auf die zur
Prüfung vorgelegten
Informationen verlassen?“

RECHTSABTEILUNG

„Können wir nachweisen,
wie ein Ergebnis
entstanden ist und geprüft
wurde?“

EXTERNE KANZLEI

„Kann ich die Belege hinter
einem Ergebnis einsehen
und einen Fehler
nachvollziehen?“

ARBEITSRECHT (FACHANWALTSCHAFT)

„Bewahrt das System
Unsicherheit, statt sie
stillschweigend zur
Tatsache zu machen?“

Lesehinweis: Die Seiten 1–12 erläutern die Methode anhand eines synthetischen Route-D-Falls. Die
Seiten 13–15 berichten die tatsächlich gemessene Baseline **golden-2026-09-25**,
einschließlich der Schwächen. Jede Seite hat eine *Technische Sicht* mit Mechanismus,
Kennungen und Quellen für das Engineering-Team.

Bevor man sich auf einen Fall stützt, zählen sechs Fragen

Die Evaluation folgt den Fragen, die Fachleute an jeden Aufnahmeprozess stellen würden. Jede Frage ist eine Evaluationsebene mit eigenen Belegen und Kennzahlen.

1

Lesen

Hat ARAM die Quellinformationen korrekt erfasst?

L0

2

Verstehen

Hat ARAM jedes Dokument erkannt und dem richtigen Regelpaket zugeordnet?

L1

3

Finden

Hat ARAM die erwarteten Fakten gefunden, jeweils mit Beleg?

L2

Menschliche Verifikation

- Hat ein Mensch jeden vorgeschlagenen Wert ausdrücklich bestätigt, korrigiert, verworfen oder als unbekannt markiert?

H1

4

Aufbauen

Sind Fakten, Konflikte und Prüfentscheidungen in den richtigen Fallfeldern angekommen?

L3

5

Prüfen

Ist der entstandene Fall strukturell vollständig und in sich gültig?

L4

6

Verifizieren

Hat der gesamte Ablauf aus Maschine und Review den erwarteten Fall ergeben?

L5


Technische Sicht

Die Ebenen folgen dem Repository: L0 Document Recovery, L1 Classification, L2 Fact Extraction, **H1 Human Candidate Verification**, L3 Case Transformation, L4 Schema & Invariants, L5 End-to-End Product. H1 liegt zwischen L2 und L3: L2-Kandidaten sind PROPOSED ; H1 macht daraus CONFIRMED / CORRECTED / REJECTED / UNKNOWN . L3 verarbeitet nur H1-verifizierte Fakten. L2 wird vor H1 bewertet; eine menschliche Korrektur „repariert“ keine L2-Kennzahlen.

Quellen: Case_Intake_Evals_and_Testing_harness/README.md (Evaluationsarchitektur); Evals Layer 0 - 5/README_LAYER_2_Fact_Extraction.md §3.4–3.5, §7.4.

ARAM legt die Prüfung ab, schreibt aber nicht den eigenen Lösungsschlüssel.

Jeder Testfall beginnt mit einer einzigen maßgeblichen Definition. Daraus entstehen getrennt voneinander zwei Dinge: die Dokumente, die ARAM sehen darf, und das erwartete Ergebnis, das ARAM nie zu sehen bekommt.



Beispiel Route D: `sut_visible/` enthält die neun PDFs und ein neutrales Manifest; Lösungsschlüssel, Review-Skript und Fixture-Spezifikation bleiben verborgen. Genau das prüft die Invariante INV-D-006.

Das erwartete Ergebnis wird unabhängig aus der eingefrorenen Testfalldefinition und dem Vertrag abgeleitet. Das geprüfte System erhält niemals Material aus dem Lösungsschlüssel.

Technische Sicht

- **Oracle-Unabhängigkeit:** Eine Fixture-/Oracle-Komponente darf die produktive Implementierung des bewerteten Verhaltens weder importieren noch aufrufen, deren Ausgaben kopieren oder sie wiederverwenden. Jede Route-D-Oracle-Datei deklariert `sut_modules_imported: []`, `uses_tauri_predictions: false`, `uses_production_mapper_as_oracle: false`, `uses_production_extractor_as_oracle: false`. Erlaubt sind nur geteilte Primitive (ISO-8601-Parser, SHA-256).
- **SUT-Isolation:** Nie sichtbar für das SUT sind `fixture_spec.yaml`, `oracle/`, Golden-Freigaben, erwartete Labels/Kandidaten-IDs, Listen verbotener Kandidaten, der Validierungsbericht und verdeckte semantische Tags. Ein Leakage-Gate prüft sichtbaren PDF-Text, PDF/XMP-Metadaten, Dateinamen, Anhänge, strukturierte Eingaben und Pfade.

Quellen: TAURI_INTAKE_DATASET_AGENT_DESIGN.md §7.3, §34; EVALS_DATASET_AND_GROUND_TRUTH_DESIGN.md §16, §22; CASE-RD-06824/oracle/*.yaml.

Ein System führt die Prüfung durch. Ein anderes bewertet sie.

Durchführung und Bewertung sind getrennte Aufgaben zweier getrennter Komponenten. So kann die Aufzeichnung dessen, was ARAM getan hat, nicht von der späteren Bewertung beeinflusst werden.

Test-Harness

„Prüfung durchführen und protokollieren.“

- Prüft, ob der Testfall zulässig ist und die Hashes stimmen
- Gibt ARAM nur die erlaubten Eingaben
- Führt das echte Intake-Verhalten aus
- Erfasst auf jeder Ebene einen Checkpoint
- Erfasst die Review-Aktionen
- Sichert alle Laufartefakte unter einem Run-Manifest

Er bewertet nicht.

Evaluation-Harness

„Prüfung bewerten und erklären.“

- Validiert die Evaluationseingaben
- Gleicht Erwartung und Ergebnis ab
- Berechnet Kennzahlen mit ausgewiesenem Zähler und Nenner
- Vergibt für jede Zeile einen Bewertungsstatus
- Klassifiziert Fehler und ermittelt ihren Ursprung
- Erstellt Berichte und Baseline-Vergleiche

Er führt das Produkt nicht aus.

Der Test-Harness protokolliert, was ARAM tatsächlich getan hat. Der Evaluation-Harness entscheidet unabhängig, wie dieses Verhalten bewertet wird.

Technische Sicht

Run-Modi (Test-Harness §3): `isolated`, `end_to_end`, `scripted_review` (L5-A), `interactive_review` (L5-B). Jeder Lauf schreibt ein Manifest (`run_id`, `fixture_version`, `fixture_spec_hash`, `evaluation_contract_hash`, `intake_version`, `harness_version`, `injected_oracle_hashes`, ...). Bewertungsstatus und Fehlerklassifikation existieren nur im Evaluation-Harness (§3, §12–14).

Quellen: `TAURI_INTAKE_TEST_HARNESS_DESIGN.md` ; `TAURI_INTAKE_EVALUATION_HARNESS_DESIGN.md` .

Ein Testfall muss sich das Recht verdienen, ARAM zu bewerten

Bevor ein Testfall zählt, muss er sieben Gates bestehen. Bevor er Teil des Golden-Sets wird, müssen Menschen jede kritische Tatsache und jede Herkunftsangabe freigeben.

Sieben Abnahme-Gates

G0 Vertragsbindung

Der Evaluationsvertrag ist auflösbar und sein Hash stimmt; die Oracle-Unabhängigkeit ist erklärt.

G1 Integrität der Fixture-Spezifikation

Schema besteht; Autorität kritischer Fakten gültig; IDs eindeutig; Status stimmig.

G2 Quell- / Build-Integrität

Erforderliche Fakten exakt eingebracht; keine undeklarierten kritischen Werte.

G3 Integrität der gerenderten Belege

Jeder erforderliche Beleg existiert auf der gerenderten Seite und stimmt überein.

G4 Mutationsintegrität

Jede gewollte Verfremdung (z. B. Scan-Artefakt) ist deklariert und ihre Wirkung dokumentiert.

G5 Oracle-Integrität

Der Lösungsschlüssel ist unabhängig erstellt; menschliche Entscheidungen werden nicht geraten.

G6 Isolation / Replay / Paket

ARAM sieht den Lösungsschlüssel nicht; das Paket ist vollständig und per Hash reproduzierbar.

Scheitert ein Pflicht-Gate, wird der Testfall aus der Produktbewertung genommen.
Ein fehlerhafter Testfall kann ARAMs Ergebnis weder senken noch anheben.

Stufen der Freigabe

GENERATED

Vom Fixture-Generator erzeugt. Noch nicht vertrauenswürdig.

VALIDATED_STRESS

Automatische Gates bestanden. Für Stresstests nutzbar.

GOLDEN

Jede kritische Tatsache und ihre Herkunft von Menschen geprüft und freigegeben.

FROZEN_REGRESSION

Artefakt-Hashes eingefroren. In Regressionstests aufgenommen.

„Der Agent kann seine eigene Ausgabe nicht freigeben.“ Eine Golden-Freigabe erfordert Evaluation Engineer und fachliche Prüfung, mit 100 % Prüfung der kritischen (Tier-1-)Fakten und 100 % Prüfung ihrer Herkunft. Jede Änderung am Hash eines geprüften Artefakts macht die Freigabe ungültig.

Technische Sicht

- Gates G0–G6: Contract Lock · Fixture-Spec Integrity · Source/Build Integrity · Rendered Evidence Integrity · Mutation Integrity · Oracle Integrity · Isolation/Replay/Package Integrity.
- Vollständige Stufenfolge: GENERATED → VALIDATED_STRESS → evaluation-engineering review → domain plausibility review → 100% Tier-1 fact review → 100% Tier-1 provenance review → expected case/review-state approval → GOLDEN → frozen artifact hashes → FROZEN_REGRESSION .
- Freigabedatensatz approvals/golden_review.yaml, Rollen EVALUATION_ENGINEER und DOMAIN_REVIEWER . Kompatibilitätsstatus: ACTIVE_CURRENT , ACTIVE_LEGACY , DEPRECATED , QUARANTINED . Datensatz-Splits: DISCOVERY , REGRESSION , HELD_OUT_VALIDATION , HUMAN_STUDY ; ein Testfall darf den Split nicht stillschweigend wechseln.
- Tier-1 = eine Tatsache, deren falscher Wert Route, Gate, Frist oder die Richtigkeit des verifizierten Falls ändern kann.

Quellen: EVALS_DATASET_AND_GROUND_TRUTH_DESIGN.md §9, §18, §20–21;
TAURI_INTAKE_DATASET_AGENT_DESIGN.md §39, §41–42; TAURI_INTAKE_EVAL_REGRESSION_CI_DESIGN.md §10–11.

Ein Fall. Sieben Prüfpunkte.

Synthetischer Route-D-Fall **CASE-RD-06824** : außerordentliche verhaltensbedingte Kündigung einer schwangeren Arbeitnehmerin; die Zulässigkeitserklärung der Behörde lag vor der Kündigung vor. Der Zugangsnachweis ist absichtlich mangelhaft.

Der Fall (synthetisch)

Neun deutsche Dokumente: Personalakte (Status), Untersuchungsbericht, Kenntnis- und Fristvermerk, Entscheidungsvermerk, Behördenzustimmung, Kündigungsschreiben, Einlieferungsbeleg, Online-Sendungsstatus, Evidenzregister.

- DOC-001 personalakte_status
- DOC-002 untersuchungsbericht
- DOC-003 kenntnis_fristvermerk
- DOC-004 entscheidungsvermerk
- DOC-005 behördenzustimmung
- DOC-006 kuendigungsschreiben
- DOC-007 einlieferungsbeleg
- DOC-008 sendungsstatus
- DOC-009 evidenzregister

Schlüsseldaten im Lösungsschlüssel

Beginn des Arbeitsverhältnisses	2022-03-01
Auslösender Vorfall	2026-04-02
Vollständige Kenntnis der kündigungsberechtigten Person	2026-04-07 11:20
Behördliche Zulässigkeitserklärung (Mutterschutz)	2026-04-17
Kündigung ausgestellt	2026-04-18 16:10
Zwei-Wochen-Frist (§ 626 BGB)	2026-04-21
Sendungsstatus „ZUGESTELLT“	2026-04-20 (kein Zugangsnachweis)

L0 Hat ARAM Quelltext und Werte originalgetreu erfasst?

WAS GEPRÜFT WIRD

- Kritische Textstellen und Werte
- Seitenerfassung und -zuordnung
- Richtiger Wiederherstellungspfad
- Sicheres Anhalten, wenn eine Seite unlesbar ist

IN DIESEM FALL

Der Kenntniszeitpunkt **2026-04-07T11:20:00+02:00** muss exakt aus DOC-003, Seite 1, erfasst werden.

BASELINE-ERGEBNIS · CASE-GD-06824

- Wiederherstellung kritischer Textstellen: **100,0 %**
- Genauigkeit kritischer Werte: **100,0 %**
- Seitenwiederherstellung & -zuordnung: **100,0 %**
- Genauigkeit des Wiederherstellungspfads: **100,0 %**

Technische Sicht

Oracle: oracle/l0_recovery.yaml. Kennzahl #5 Rate unsicherer Fortsetzung (unsafe_continuations / fail_closed_opportunities) hatte in dieser Baseline in keinem der 40 Jobs auswertbare Einheiten.

L1 Hat ARAM jedes Dokument erkannt und dem richtigen Regelpaket zugeleitet?

WAS GEPRÜFT WIRD

- Dokumenttyp je Dokument
- Falsche Zuordnungen mit hoher Sicherheit
- Routing ins Regelpaket
- Enthaltung oder Markierung bei echter Mehrdeutigkeit

IN DIESEM FALL

Alle neun Dokumente sollen an **extraordinary_termination_rule_pack** gehen. DOC-008 muss als **POSTAL_TRACKING_STATUS** erkannt werden, also als Sendungsverfolgung und nicht als Zustellnachweis.

BASELINE-ERGEBNIS · CASE-GD-06824

- Klassifikationsgenauigkeit: **41,7 %**
- Rate falsch-sicherer Klassifikation ↓: **37,5 %**
- Rate falschen Regelpaket-Routings ↓: **50,0 %**
- Korrekte Enthaltung / Mehrdeutigkeit: **50,0 %**

Technische Sicht

Oracle: oracle/l1_classification.yaml (expected_type , expected_routing , ambiguity_required). Isolierte L1-Läufe erhalten die bekannt richtige L0-Ausgabe; ein L1-Wert ist daher nicht durch L0-Fehler verfälscht.

L2 Hat ARAM die erwarteten Fakten mit Beleg gefunden und sich dort enthalten, wo es muss?

WAS GEPRÜFT WIRD

- Erwartete Fakten gefunden (Recall), nichts Überflüssiges (Präzision)
- Korrekte Werte
- Belegspur für jeden Kandidaten
- Sichere Enthaltung, wo eine Regel eine Schlussfolgerung verbietet

IN DIESEM FALL

Das Sendungsdatum 2026-04-20 ist ein erwarteter *Kandidat* (CAND-071). Der Lösungsschlüssel führt zudem **verbotene Kandidaten**: `termination_received_at = 2026-04-20` und `delivery_proof = true`.

BASELINE-ERGEBNIS · CASE-GD-06824

Fakten-Recall: **42,9 %**

Fakten-Präzision: **54,5 %**

Wertgenauigkeit: **100,0 %**

Rate sicherer Regel-Enthaltung: **100,0 %**

Belegrückverfolgbarkeit der Kandidaten: **75,0 %**

Technische Sicht

Oracle: `oracle/l2_candidates.yaml` mit `forbidden_candidates`. Fakten-Recall = `matched_expected_candidates / expected_extractable_candidates`; Fakten-Präzision = `matched_actual_candidates / scored_actual_candidates`. L2 wird vor H1 gespeichert und bewertet.

H1 Erhält jeder vorgeschlagene Wert eine ausdrückliche menschliche Entscheidung?

WAS GEPRÜFT WIRD

- Entscheidung je Wert: bestätigen, korrigieren, verwerfen, als unbekannt markieren
- Quellstelle eingesehen
- Widersprüchliche Kandidaten verglichen

IN DIESEM FALL

Geskriptetes Review in diesem Fall: `REV-071 REJECT delivery_date` („Tracking status cannot establish receipt.“) und `REV-077 MARK_UNKNOWN termination_received_at`.

BASELINE-ERGEBNIS · CASE-GD-06824

H1 hat keine eigene Kennzahl. Die Wirkung wird in L3 (bestätigte Fakten bleiben erhalten) und L5 (Fehler, die das Review passieren) gemessen.

Technische Sicht

Jeder vorgeschlagene, aus Dokumenten abgeleitete Wert braucht eine ausdrückliche H1-Entscheidung, bevor er zur bestätigten Tatsache wird. L3-Diagnosen umfassen „H1 Correction Override Rate“ und „H1 Authority Violation Rate“ (Ziel 0 %). Quelle: Layer-READMEs L2 §7.4, L3 §8, §12.

L3 Sind bestätigte Fakten, Konflikte und Prüfstatus unverändert in den richtigen Fallfeldern angekommen?

WAS GEPRÜFT WIRD

- Feldzuordnung
- Erhalt bestätigter Fakten
- Abgeleitete Felder
- Konflikte bleiben sichtbar; kein stilles Überschreiben; Herkunft bleibt erhalten

IN DIESEM FALL

11 erwartete Felder. `termination_received_at` muss `REVIEW_REQUIRED` bleiben, Begründung: „Tracking assertion is not accepted as receipt proof“. Die Herkunft des verworfenen Tracking-Kandidaten bleibt erhalten.

BASELINE-ERGEBNIS · CASE-GD-06824

Genauigkeit der Feldzuordnung: **87,5 %**

Erhalt bestätigter Fakten: **85,7 %**

Vollständigkeit der Transformation: **87,5 %**

Konflikt- & Herkunftssicherheit: **100,0 %**

Technische Sicht

Oracle: `oracle/l3_transformation.yaml`. Isolierte L3-Eingabe = `oracle/l2_candidates.yaml` + `reviewer/scripted_actions.yaml`. Konflikt- & Herkunftssicherheit = `passed_conflict_and_provenance_assertions / applicable_safety_assertions`.

L4 Ist der Fall strukturell gültig und in sich stimmig?

WAS GEPRÜFT WIRD

- Schema-Gültigkeit
- Pflichtfelder vorhanden
- Invarianten (Regeln, die immer gelten müssen)
- Gültige Beweisstatus

IN DIESEM FALL

- INV-D-001 2026-04-07 + 14 Tage = 2026-04-21
- INV-D-003 Zustimmung 2026-04-17 liegt vor Ausstellung 2026-04-18
- INV-D-004 Sendungsdatum wird nicht zum bestätigten Zugang

BASELINE-ERGEBNIS · CASE-GD-06824

Schema-Bestehensrate: **100,0 %**

Vollständigkeit der Pflichtfelder: **100,0 %**

Gültigkeit der Beweisstatus: **100,0 %**

Technische Sicht

Oracle: oracle/l4_case_and_assertions.yaml (6 Invarianten INV-D-001...006, Beweisstatus ED-11 und EU-WF DEFECTIVE). Hinweis: Kennzahl #23 Invarianten-Bestehensrate hatte in dieser Baseline über alle 40 Golden-Testfälle *keine auswertbaren Einheiten*. Das Engineering sollte klären, ob Invarianten-Assertions im Golden-Set verdrahtet sind.

L5 Hat der gesamte Ablauf aus Maschine und Review exakt den erwarteten verifizierten Fall ergeben?

WAS GEPRÜFT WIRD

- Strikter Erfolg des gesamten Falls
- Genauigkeit kritischer (Tier-1-)Felder
- Kritische Fehler, die das Review passieren

IN DIESEM FALL

Strikter Erfolg verlangt: alle Tier-1-Werte und -Status korrekt, `termination_received_at` bleibt `REVIEW_REQUIRED`, `delivery_proof` bleibt `false`, kein kritischer Konflikt wird stillschweigend verworfen.

BASELINE-ERGEBNIS · CASE-GD-06824

Rate strikt verifizierter Fälle: **0,0 %**

Genauigkeit kritischer Felder: **50,0 %**

Durchschlupfrate kritischer Fehler : **83,3 %**

Aktionsaufwand im geskripteten Review: **9,1 %**

Technische Sicht

Oracle: oracle/l5_case_and_review.yaml, review_population: SCRIPTED_L5_A. Menschlicher Korrekturaufwand: NOT_SCORED („L5-A scripted regression is not real-human telemetry“). Der Aktionsaufwand im geskripteten Review ist DIAGNOSTIC_ONLY .

Zur Zuordnung: Dokumente und Erwartungswerte stammen aus dem Datensatz-Testfall CASE-RD-06824 (Status VALIDATED_STRESS, nicht GOLDEN). Die gezeigten Ergebnisse gehören zu CASE-GD-06824, dem Route-D-Testfall mit derselben Fallnummer in der Golden-Baseline. Das Repository dokumentiert das Verhältnis beider Fassungen nicht; die Zuordnung ist daher als Illustration zu lesen.

Ein Fakt darf sich nicht von seinem Beleg lösen.

Für jeden bestätigten Wert hält der Lösungsschlüssel fest, woher er stammt, bis auf die Seite und die Stelle auf der Seite. Die Evaluation prüft, ob ARAM diese Kette intakt hält.

FALLFELD
knowledge_date
✓ CONFIRMED 2026-04-07T11:20:00+02:00

↓

EXTRAHIERTER KANDIDAT
CAND-026 · ASSERT-026
In L2 vorgeschlagen, in H1 bestätigt

↓

QUELLVERWEIS
DOC-003 · Seite 1 · ANCHOR-DOC-003-001
bbox [204.09, 665.82, 313.34, 677.82] · Kenntniszeitpunkt

↓

GEPINNTES QUELLARTEFAKT
sha256:e31d98e885dd17acc25e9022fe68ed22929bcd0e21d718d0f824fe9cf2ec0386
SHA-256 des gerenderten Dokuments

Kennnis- und Fristvermerk

2026-04-07 | DOC-003 | CASE-RD-06824

Der Fristvermerk trennt Ereignisdatum, vollständige positive Kenntnis des kündigungsberechtigten Entscheidungsträgers und berechnete Zwei-Wochen-Frist.

Kennniszeitpunkt	2026-04-07T11:20:00+02:00
Kündigungsberechtigte Stelle	PERSON-HR-01 (Leitung Personal)
Kennniskette	Compliance review -> HR case conference -> authorized decision-maker received the complete evidence packet.
Zwei-Wochen-Frist endet	2026-04-21
Kündigung ausgestellt am	2026-04-18T16:10:00+02:00
Frist eingehalten	Ja / true

DOC-003 „Kenntnis- und Fristvermerk“, Seite 1. Die markierte Stelle ergibt sich aus der Bounding Box im Lösungsschlüssel und wurde nicht von Hand gesetzt.

HR

Woher stammt dieser Wert?

Rechtsabteilung

Kann das Unternehmen den Belegweg erklären?

Externe Kanzlei / Arbeitsrecht

Lässt sich die behauptete Tatsache bis zur Quelle zurückverfolgen?

Technische Sicht

Herkunftsdatensatz oracle/provenance.yaml: anchor_id, assertion_id, candidate_id, page, bbox (PDF_POINTS_BOTTOM_LEFT), source_text, artifact_hash. Gemessen durch L2 #15 Belegrückverfolgbarkeit(candidates_with_valid_trace / candidates_requiring_provenance) und L3 #20 Konflikt- & Herkunftssicherheit.

Geprüft wird der Umgang mit Unsicherheit, nicht nur mit einfachen Antworten.

In diesem Fall meldet die Online-Sendungsverfolgung am 2026-04-20 „ZUGESTELLT“. Es gibt weder einen Auslieferungsbeleg noch eine identifizierte Zustellperson. Ein System, das das Datum einfach übernimmt, würde ein Zugangsdatum erzeugen, das die Beweislage nicht trägt.

Online-Sendungsstatus
2026-04-20 | DOC-008 | CASE-RD-08824

Synthetische Statusanzeige. Der Status behauptet eine Zustellung, enthält aber keinen Auslieferungsbeleg und keine identifizierte Zustellperson.

Sendungsnummer	RR0418265100E
Status	ZUGESTELLT
Statusdatum	2026-04-20
Auslieferungsbeleg vorhanden	Nein / false

DOC-008 „Online-Sendungsstatus“. Rot: das Statusdatum, ein Kandidat, der nicht zum Zugangsdatum werden darf. Gelb: „Auslieferungsbeleg vorhanden: Nein / false“.

Was der Lösungsschlüssel erwartet

Der Zugang bleibt offen und wird von einem Menschen entschieden, statt zur Tatsache zu werden.

FELD	ERWARTETER STATUS (LÖSUNGSSCHLÜSSEL)
delivery_method	✓ CONFIRMED REGISTERED_MAIL
delivery_proof	✓ CONFIRMED false
termination_received_at	👁 REVIEW_REQUIRED null

✗ Durchgefallen

Stille Festlegung

- termination_received_at = 2026-04-20 aus der Sendungsverfolgung übernommen
- delivery_proof = true
- Der Konflikt verschwindet aus dem Fall

✓ Bestanden

Unsicherheit bewahren

- Sendungsdatum bleibt Kandidat, mit Quelle
- Zugang bleibt REVIEW_REQUIRED / unbekannt
- Review verwirft das Datum und markiert den Zugang als unbekannt
- Herkunft des verworfenen Kandidaten bleibt erhalten

Wichtige Einordnung.

Gezeigt wird *geprüftes Systemverhalten* im Umgang mit Belegen, Unsicherheit, Herkunft und Prüfstatus. Es wird nicht gezeigt, dass eine rechtliche Schlussfolgerung zu Zugang, Fristen oder Wirksamkeit einer Kündigung richtig ist.

Technische Sicht

- forbidden_candidates in oracle/l2_candidates.yaml: termination_received_at = 2026-04-20 („Online tracking status is not authoritative proof of actual receipt in this fixture.“) und delivery_proof = true .
- Evidenzprofil: ED-11 und EU-WF = PROVENANCE_INVALID / DEFECTIVE .
- Invarianten INV-D-004 und INV-D-005 .
- Ein stillschweigend verworfener kritischer Konflikt ist ein CI-Blocker ohne Toleranz.

Das Review gehört zum Ablauf, und geskriptetes Review wird von echtem menschlichem Review getrennt.

ARAM schlägt vor, ein Mensch entscheidet. Die Evaluation misst das an drei getrennten Stellen und legt sie nie zusammen.

Bestätigen Wert ist richtig

Korrigieren Wert ersetzt

Verwerfen Kandidat verworfen

Auflösen Konflikt entschieden

Unbekannt Beleglage unzureichend

H1

Menschliche Kandidatenprüfung

Jeder vorgeschlagene Wert braucht eine ausdrückliche Entscheidung, bevor er zur bestätigten Tatsache wird.

Indirekt in L3 und L5 bewertet. Korrigiert nie nachträglich L2-Werte.

L5-A

Geskriptetes Regressions-Review

Ein festes, reproduzierbares Review-Skript steuert den gesamten Produktablauf. Es zeigt, dass sich der Ablauf von Lauf zu Lauf gleich verhält.

Skript für CASE-RD-06824: 77 Aktionen

✓ CONFIRM × 75

✗ REJECT × 1

👁 MARK_UNKNOWN × 1

Aktionsaufwand im geskripteten Review (Diagnose)

17,3 %_{69/398}

L5-B

Studie mit echten Prüfpersonen

Echte Prüfpersonen nach einem festgelegten Protokoll. Nur diese Gruppe kann zeigen, wie viel Korrekturarbeit Menschen tatsächlich leisten.

Menschlicher Korrekturaufwand ↓

—

nicht berechnet: keine auswertbaren Einheiten

Diese Baseline enthält keine L5-B-Studie.

Nie vermischt. Der menschliche Korrekturaufwand gehört ausschließlich zur L5-B-Studie mit echten Personen. In dieser Baseline steht dort „—“ (keine auswertbaren Einheiten), nicht 0 %. Der geskriptete Lauf berichtet stattdessen eine eigens benannte Diagnose.

Technische Sicht

Run-Modi: scripted_review (L5-A, deterministische Review-Skripte) vs. interactive_review (L5-B, Telemetrie echter Prüfpersonen). Human Correction Burden = (corrected_machine_suggestions + manual_field_entries + manually_resolved_conflicts) / reviewed_fields, nur L5-B. scripted_review_action_burden darf die kanonische Metrik-ID von Human Correction Burden nicht verwenden. Die Durchschlupfrate kritischer Fehler wird für L5-A und L5-B getrennt berichtet.

Ein falscher Endfall allein sagt zu wenig.

Ende-zu-Ende-Tests zeigen, dass ein Fall gescheitert ist. Isolierte Tests geben jeder Ebene bekannt richtige Eingaben aus dem Lösungsschlüssel, sodass jede Fähigkeit für sich gemessen wird.

GEPRÜFTE EBENE	ERHÄLT BEKANNT RICHTIGE EINGABE	WAS DADURCH ISOLIERT WIRD
L1	Erfasster Text aus dem Lösungsschlüssel oracle/l0_recovery.yaml	Klassifikationsqualität, unabhängig von Lesefehlern
L2	Erfasster Text + korrekte Klassifikation oracle/l0_recovery.yaml + oracle/l1_classification.yaml	Extraktionsqualität, unabhängig von Lese- und Routingfehlern
L3	Korrekte Kandidaten + geskriptete Review-Entscheidungen oracle/l2_candidates.yaml + reviewer/scripted_actions.yaml	Transformationsqualität, unabhängig von Extraktions- und Reviewfehlern
L4	Korrekter transformierter Fallstatus oracle/l3_transformation.yaml	Strukturelle Gültigkeit, unabhängig von vorgelagerten Fehlern
L5	Keine Injektion: der gesamte Ablauf full workflow	Was Nutzerinnen und Nutzer tatsächlich erleben

Ende-zu-Ende-Tests zeigen, dass ein Fall gescheitert ist. Isolierte Tests helfen zu erkennen, welche Fähigkeit den Fehler eingebracht hat.


Als Ursache gilt die **früheste kausal hinreichende Abweichung**, ermittelt entlang der aufgezeichneten Herkunftskette und nicht durch die Annahme, die früheste Ebene sei schuld. Mitursachen werden getrennt festgehalten. Beispiel: Liest L0 ein Datum falsch und übernimmt das Review es, ist L0 die Hauptursache und `HUMAN_REVIEW_ESCAPE` wird zusätzlich erfasst.

Technische Sicht

Die injizierten Eingaben sind kompilierte Schnittstellen, keine unabhängig verfassten Wahrheitsdateien; jedes injizierte Artefakt ist per Hash an Fixture-Manifest und Vertragsversion gebunden (Test-Harness §5). Im Run-Manifest erscheinen sie als `injected_oracle_hashes`. Isolierte Qualität wird getrennt von der Ende-zu-Ende-Qualität berichtet (L0–L5-Design §6). Kausalregel: Kausalität nicht allein aus der Ebenenreihenfolge ableiten (§11).

Ein fehlerhafter Test darf nicht als Produktfehler erscheinen.

Jede bewertete Zeile trägt einen Status. Nur Zeilen mit `SCORED` fließen in eine Produktkennzahl ein. Ein defekter Testfall, eine Vertragslücke oder ein Absturz des Harness wird getrennt diagnostiziert und wird nie zu einer Null in ARAMs Ergebnis.



Ein echtes Beispiel: Route C

Der Evaluationsvertrag des Route-C-Testfalls verlangt stets bestimmte Belege zur Sozialauswahl (EC-2 bis EC-6). Das zugrunde liegende Szenario, eine vollständige Betriebsschließung, macht eine Sozialauswahl jedoch entbehrlich. Statt einen Auswahlpool zu erfinden, um den Vertrag zu bedienen, markiert der Testfall die betroffenen Assertions als nicht bewertet, bis die Vertragsverantwortlichen die Lücke klären (CG-001, dazu eine zweite Lücke, CG-002).

```
route_c_2_AZR_276_16_dataset/oracle/l4_case_and_assertions.yaml →
NOT_SCORED_CONTRACT_ERROR_FOR_AFFECTED_ASSERTIONS
```

In dieser Baseline

Alle 240 Jobs in `golden-2026-09-25` waren `SCORED`; nichts wurde ausgenommen. Wo eine Kennzahl nichts zu messen hatte, steht „—“, nicht 0 %.

Technische Sicht

Status: `SCORED`, `NOT_APPLICABLE`, `NOT_SCORED_EXECUTION_ERROR`, `NOT_SCORED_CONTRACT_ERROR`, `NOT_SCORED_FIXTURE_DEFECT`. Ein Fixture-Defekt senkt keine Produktkennzahlen; die CI lässt aber den Job der Evaluationsinfrastruktur scheitern, wenn ein erforderlicher Regressionstestfall nicht mehr bewertbar ist. Quarantäne: `NOT_SCORED_FIXTURE_DEFECT` setzen → aus Nennern entfernen → nach `QUARANTINED` verschieben. Nicht bewertbaren Testfällen werden keine Produkt-Ursachenebenen zugewiesen.

Quellen: `TAURI_INTAKE_EVALUATION_HARNESS_DESIGN.md` §3, §13;
`TAURI_INTAKE_EVAL_REGRESSION_CI_DESIGN.md` §7, §12; `Route C README.md`, `fixture_spec.yaml`
`(GENERATED_CONTRACT_REVIEW_REQUIRED)`, `approvals/golden_review.yaml` (`PENDING_HUMAN_REVIEW`).

Ein entdeckter Fehler wird zu einer dauerhaften Regressionsprüfung.

Die Evaluation erzeugt reproduzierbare Nachweise, keine Einmal-Demonstrationen. Jeder Lauf ist an exakte Versionen und Hashes gebunden, sodass Ergebnisse wiederholbar sind und Behebungen belegt werden können.

1
Evaluation findet einen Fehler

2
Ursache ermittelt

3
Produkt oder Test behoben

4
Derselbe kontrollierte Fall erneut ausgeführt

5
Behebung belegt

6
Fall in die Regression eingefroren

7
CI prüft jede künftige Änderung

Drei CI-Stufen

Pull Request
Unit- und Vertragstests, Regression der betroffenen Ebenen, Sicherheits-Testfälle, ausgewählte Ende-zu-Ende-Smoke-tests.

Main / Release
Vollständige Regressionssuite, isolierte L0–L4-Evaluatoren, geskriptete L5-A-Fälle, Baseline-Delta-Bericht.

Release Candidate
Eingefrorene Held-out-Evaluation, vollständige Ende-zu-Ende-Validierung und eine L5-B-Teilmenge mit echten Personen, wenn Aussagen zum menschlichen Ablauf getroffen werden.

Produkt-Blocker ohne Toleranz (bei jeder neuen Regression)

- ✗ Tier-1-Richtigkeit

✗ Unsichere Fortsetzung

✗ Stilles Überschreiben

✗ Kritische Invariante verletzt

✗ Falsches Regelpaket erreicht Extraktion

✗ Kritischer Konflikt stillschweigend verworfen

✗ Sicherheits-Durchschlupf im L5-A-Skript

✗ Schema-Regression bei eingefrorenen Testfällen

Jeder Lauf ist gepinnt

<code>run_id</code> dieser Lauf	<code>fixture_version</code> Testfallversion	<code>fixture_spec_hash</code> Testfalldefinition	<code>evaluation_contract_hash</code> Bewertungsvertrag	<code>intake_version</code> ARAM-Build	<code>harness_version</code> Harness-Build	<code>injected_oracle_hashes</code> bekannt richtige Eingaben
------------------------------------	---	--	--	---	---	--

Technische Sicht
Replay-Modi: `BYTE_REPLAYABLE` , `SEMANTICALLY_REPLAYABLE` , `FROZEN_ONLY` . Ein Replay erzeugt eine neue Run-ID und verweist per `replay_of` auf das Original. Der Baseline-Vergleich berichtet `new_failures` , `fixed_failures` , `persistent_failures` , `fixture_defects` , `contract_errors` , `metric_deltas` . Inkompatible Bewertungssemantik wird nicht so verglichen, als handle es sich um dieselbe Baseline.

Quellen: `TAURI_INTAKE_EVAL_REGRESSION_CI_DESIGN.md` §3–4, §6, §9;
`TAURI_INTAKE_TEST_HARNESS_DESIGN.md` §8, §10.

Baseline golden-2026-09-25: was gemessen wurde

Dies sind die gemessenen Ergebnisse der ersten Golden-Baseline. Jeder Wert steht mit Zähler und Nenner. Kennzahlen ohne Messgegenstand sind mit „—“ markiert und werden nie als 0 % dargestellt.

Quelle Evals_Illustrative_docs/metrics_golden-2026-09-25.md — Werte, Zähler/Nenner und Richtung per Skript übernommen, nicht abgetippt.

Evaluationskontext

BASELINE golden-2026-09-25	ERSTELLT 2026-09-25T04:54:38Z
DATENSATZ TAURI-DE-GOLDEN-40	SUITE main
BEWERTETE JOBS 240 / 240 SCORED	AUSGENOMMEN / NICHT BEWERTET 0
TESTFÄLLE 40 · A 5 · B 3 · C 7 · D 25	INTAKE-BUILD · VERTRAGS-HASH · HARNESS-VERSION im Quellbericht nicht angegeben

So sind die Zahlen zu lesen. Prozent = gepoolter Zähler ÷ gepoolter Nenner über alle Jobs, in denen die Kennzahl berechnet wurde (einheitengewichtet). ↓ kennzeichnet eine Rate, bei der niedriger besser ist. Der Bericht ist beschreibend und legt für sich genommen keine Bestehensgrenzen fest.

Ergebnisse nach Kundenfrage

■ höher ist besser ■ ↓ niedriger ist besser 🧩 — nicht berechnet (nicht 0 %)

L0 Lesen: Dokumentwiederherstellung *Wurden die Quelldokumente originalgetreu erfasst?*

Wiederherstellung kritischer Textstellen #1 · l0.critical_text_recovery_rate		100,0 %	404/404
Genauigkeit kritischer Werte #2 · l0.critical_value_accuracy		100,0 %	404/404
Seitenwiederherstellung & -zuordnung #3 · l0.page_recovery_association_accuracy		100,0 %	784/784
Genauigkeit des Wiederherstellungspfads #4 · l0.recovery_path_accuracy		100,0 %	380/380
Rate unsicherer Fortsetzung ↓ niedriger ist besser #5 · l0.unsafe_continuation_rate		—	nicht berechnet: keine auswertbaren Einheiten

L1 Verstehen: Klassifikation & Routing *Wurden die Dokumente richtig erkannt und zugeordnet?*

Klassifikationsgenauigkeit #6 · l1.classification_accuracy		59,2 %	197/333
Rate falsch-sicherer Klassifikation ↓ niedriger ist besser #7 · l1.wrong_confident_classification_rate		21,2 %	53/250
Rate falschen Regelpaket-Routings ↓ niedriger ist besser #8 · l1.wrong_rule_pack_routing_rate		39,5 %	150/380
Korrekte Enthaltung / Mehrdeutigkeit #9 · l1.correct_abstention_ambiguity_rate		46,8 %	22/47

L2 Finden: Faktenextraktion

Wurden die erwarteten Fakten gefunden, jeweils mit Beleg?

Fakten-Recall #11 · l2.fact_recall		42,9 %	188/438
Fakten-Präzision #12 · l2.fact_precision		55,1 %	188/341
Wertgenauigkeit #13 · l2.value_accuracy		100,0 %	212/212
Rate sicherer Regel-Enthaltung #14 · l2.safe_rule_abstention_rate		99,7 %	617/619
Belegrückverfolgbarkeit der Kandidaten #15 · l2.candidate_evidence_traceability_rate		88,7 %	188/212

L3 Aufbauen: Falltransformation

Wurden Fakten, Konflikte und Prüfstatus sicher in den Fall übernommen?

Genauigkeit der Feldzuordnung #16 · l3.field_mapping_accuracy		94,8 %	273/288
Erhalt bestätigter Fakten #17 · l3.confirmed_fact_preservation_rate		84,0 %	368/438
Genauigkeit abgeleiteter Felder #18 · l3.derived_field_accuracy		—	nicht berechnet: keine auswertbaren Einheiten
Vollständigkeit der Transformation #19 · l3.transformation_completeness		94,8 %	273/288
Konflikt- & Herkunftssicherheit #20 · l3.conflict_provenance_safety		100,0 %	204/204

L4 Prüfen: Schema & Invarianten

Ist der entstandene Fall strukturell gültig und in sich stimmig?

Schema-Bestehensrate #21 · l4.schema_pass_rate		82,5 %	33/40
Vollständigkeit der Pflichtfelder #22 · l4.required_field_completeness		100,0 %	486/486
Invarianten-Bestehensrate #23 · l4.invariant_pass_rate		—	nicht berechnet: keine auswertbaren Einheiten
Gültigkeit der Beweisstatus #24 · l4.evidence_state_validity		100,0 %	1.190/1.190

L5 Verifizieren: Ende-zu-Ende

Hat der gesamte Ablauf den erwarteten verifizierten Fall ergeben?

Rate strikt verifizierter Fälle #25 · l5.verified_case_pass_rate		2,5 %	1/40
Genauigkeit kritischer Felder #26 · l5.critical_field_accuracy		63,9 %	235/368
Durchschlupfrate kritischer Fehler #27 · l5.critical_error_escape_rate		63,0 %	133/211
Menschlicher Korrekturaufwand #28 · l5.human_correction_burden		—	nicht berechnet: keine auswertbaren Einheiten
Aktionsaufwand im geskripteten Review #D1 · l5a.scripted_review_action_burden		17,3 %	69/398

Es gibt bewusst keinen Gesamtwert. Die Kennzahlen messen unterschiedliche Stufen, haben unterschiedliche Nenner (von 40 Fällen bis 1.190 Assertions), zeigen in unterschiedliche Richtungen, und einige wurden nicht berechnet. Ein Durchschnitt würde in die Irre führen.

Nach Route

Route D stellt 25 der 40 Testfälle; gepoolte Werte spiegeln daher überwiegend Route D.
Route B umfasst nur 3 Testfälle; ihre Prozentwerte sind entsprechend vorsichtig zu lesen.

KENNZAHL	ROUTE A 5 testfälle	ROUTE B 3 testfälle	ROUTE C 7 testfälle	ROUTE D 25 testfälle
Wiederherstellung kritischer Textstellen #1	100,0 % 40/40	100,0 % 31/31	100,0 % 75/75	100,0 % 258/258
Genauigkeit kritischer Werte #2	100,0 % 40/40	100,0 % 31/31	100,0 % 75/75	100,0 % 258/258
Seitenwiederherstellung & -zuordnung #3	100,0 % 77/77	100,0 % 62/62	100,0 % 174/174	100,0 % 471/471
Genauigkeit des Wiederherstellungspfads #4	100,0 % 37/37	100,0 % 31/31	100,0 % 99/99	100,0 % 213/213
Klassifikationsgenauigkeit #6	71,4 % 20/28	68,0 % 17/25	71,8 % 56/78	51,5 % 104/202
Rate falsch-sicherer Klassifikation ↓ #7	20,0 % 5/25	37,0 % 10/27	23,3 % 17/73	16,8 % 21/125
Rate falschen Regelpaket-Routings ↓ #8	35,1 % 13/37	32,3 % 10/31	27,3 % 27/99	46,9 % 100/213
Korrekte Enthaltung / Mehrdeutigkeit #9	44,4 % 4/9	16,7 % 1/6	47,6 % 10/21	63,6 % 7/11
Fakten-Recall #11	56,8 % 25/44	47,1 % 16/34	49,4 % 40/81	38,4 % 107/279
Fakten-Präzision #12	62,5 % 25/40	64,0 % 16/25	58,0 % 40/69	51,7 % 107/207
Wertgenauigkeit #13	100,0 % 28/28	100,0 % 18/18	100,0 % 42/42	100,0 % 124/124
Rate sicherer Regel-Enthaltung #14	96,7 % 59/61	100,0 % 52/52	100,0 % 149/149	100,0 % 357/357
Belegrückverfolgbarkeit der Kandidaten #15	89,3 % 25/28	88,9 % 16/18	95,2 % 40/42	86,3 % 107/124
Genauigkeit der Feldzuordnung #16	100,0 % 34/34	100,0 % 21/21	100,0 % 54/54	91,6 % 164/179
Erhalt bestätigter Fakten #17	84,1 % 37/44	85,3 % 29/34	82,7 % 67/81	84,2 % 235/279
Vollständigkeit der Transformation #19	100,0 % 34/34	100,0 % 21/21	100,0 % 54/54	91,6 % 164/179
Konflikt- & Herkunftssicherheit #20	100,0 % 25/25	100,0 % 17/17	100,0 % 44/44	100,0 % 118/118
Schema-Bestehensrate #21	100,0 % 5/5	100,0 % 3/3	85,7 % 6/7	76,0 % 19/25
Vollständigkeit der Pflichtfelder #22	100,0 % 59/59	100,0 % 38/38	100,0 % 79/79	100,0 % 310/310
Gültigkeit der Beweisstatus #24	100,0 % 149/149	100,0 % 77/77	100,0 % 224/224	100,0 % 740/740
Rate strikt verifizierter Fälle #25	20,0 % 1/5	0,0 % 0/3	0,0 % 0/7	0,0 % 0/25
Genauigkeit kritischer Felder #26	86,4 % 38/44	66,7 % 18/27	66,2 % 45/68	58,5 % 134/229
Durchschlupfrate kritischer Fehler ↓ #27	28,6 % 6/21	64,3 % 9/14	59,0 % 23/39	69,3 % 95/137

KENNZAHL	ROUTE A 5 testfälle	ROUTE B 3 testfälle	ROUTE C 7 testfälle	ROUTE D 25 testfälle
Aktionsaufwand im geskripteten Review #D1	19,6 % 9/46	13,8 % 4/29	13,3 % 10/75	18,5 % 46/248

Was die Baseline zeigt, offen dargestellt

Das Harness arbeitet wie vorgesehen: Es zeigt präzise, wo ARAM Intake heute verlässlich ist und wo es noch nicht so weit ist.

✓ Belastbare Stärken

Wiederherstellung kritischer Textstellen: **100,0 %** (404/404)
Kritischer Text in jedem Fall erfasst.

Wertgenauigkeit: **100,0 %** (212/212)
Wird ein Fakt gefunden, stimmt sein Wert.

Konflikt- & Herkunftssicherheit: **100,0 %** (204/204)
Konflikte blieben sichtbar; kein stilles Überschreiben.

Rate sicherer Regel-Enthaltung: **99,7 %** (617/619)
Enthaltung, wo Regeln es verlangen (2 Fehler bei 619).

Vollständigkeit der Pflichtfelder: **100,0 %** (486/486)

Gültigkeit der Beweisstatus: **100,0 %** (1.190/1.190)

✗ Verbesserungsbedarf

Rate strikt verifizierter Fälle: **2,5 %** (1/40)
Nur 1 von 40 Fällen bestand Ende-zu-Ende strikt.

Durchschlupfrate kritischer Fehler ↓: **63,0 %** (133/211)
Von den kritischen Maschinenfehlern beim Eintritt ins Review waren 63 % am Ende noch falsch oder ungeklärt.

Klassifikationsgenauigkeit: **59,2 %** (197/333)

Rate falschen Regelpaket-Routings ↓: **39,5 %** (150/380)
Falsch geroutete Dokumente landen im falschen Regelpaket.

Fakten-Recall: **42,9 %** (188/438)
Weniger als die Hälfte der erwarteten Fakten wurde gefunden.

Schema-Bestehensrate: **82,5 %** (33/40)
7 von 40 Fällen bestanden die Schema-Validierung nicht.

! Vorsichtig lesen

Route D stellt 25 von 40 Testfällen und dominiert gepoolte Werte; Route B hat 3.

Fünf Kennzahlen wurden nicht berechnet (keine auswertbaren Einheiten oder kein Einzelwert). Das ist nicht dasselbe wie 0 %.

Keine Daten mit echten Prüfpersonen (L5-B): Wirksamkeit des Reviews und Korrekturaufwand sind ungemessen.

Das Ende-zu-Ende-Review dieser Baseline ist geskriptet (L5-A-Diagnose für alle 40 Fälle berechnet). Echte Prüfpersonen könnten mehr oder weniger Fehler abfangen.

Intake-Build, Vertrags-Hash und Harness-Version sind im Bericht nicht angegeben.

Wo die Schwäche beginnt

Liest man die Ebenen der Reihe nach, zeigt sich ein klares Muster: Lesen ist fehlerfrei, Verstehen und Finden sind die frühesten schwachen Ebenen, und das Ende-zu-Ende-Ergebnis scheitert nachgelagert.

L0

100,0 %

Genauigkeit kritischer Werte

L1

59,2 %

Klassifikationsgenauigkeit

L2

42,9 %

Fakten-Recall

H1

keine eigene Kennzahl

L3

94,8 %

Genauigkeit der Feldzuordnung

L4

82,5 %

Schema-Bestehensrate

L5

2,5 %

Rate strikt verifizierter Fälle

Dieses Muster ist in den Ebenenkennzahlen des Berichts sichtbar. Die Ursachendatensätze je Fehler (früheste kausal hinreichende Abweichung) sind nicht Teil dieses Berichts; daher werden hier keine Fehlerzahlen je Fehlerfamilie gezeigt.

Ausnahmen

0 von 240 Jobs wurden ausgenommen. Keine Fixture-Defekte, Vertragsfehler oder Ausführungsfehler haben diese Baseline beeinflusst.

Regressionsstatus

NEW
erste Baseline

FIXED
erste Baseline

PERSISTENT
erste Baseline

Dies ist die erste Golden-Baseline; es gibt noch nichts zu vergleichen. Neue, behobene und fortbestehende Fehler werden ab der nächsten kompatiblen Baseline berichtet.

Technische Sicht

Zahlen der schwachen Ebenen (Zähler/Nenner): Klassifikationsgenauigkeit 197/333; Rate falsch-sicherer Klassifikation ↓ 53/250; Rate falschen Regelpaket-Routings ↓ 150/380; Fakten-Recall 188/438; Fakten-Präzision 188/341. L3-Kennzahlen beziehen sich auf das, was L3 erreicht hat (Feldzuordnung 273/288); deshalb können sie hoch sein, während L5 niedrig ist. Nicht berechnet: #5, #10, #18, #23, #28. Für das Engineering nachzuverfolgen: Die Invarianten-Bestehensrate hatte keine auswertbaren Einheiten, obwohl Route-D-Testfälle Invarianten deklarieren (INV-D-001...006).

Was diese Nachweise belegen und was nicht

Ein Assurance-Bericht ist nur so nützlich, wie seine Grenzen klar sind.

✓ Belegt

- Der Lösungsschlüssel ist vom geprüften System unabhängig, und ARAM kann ihn nicht einsehen.
- Das echte Intake-Verhalten wurde ausgeführt und auf jeder Ebene erfasst.
- Herkunft der Belege, Konflikte, Unsicherheit und Prüfstatus sind Teil der Prüfung.
- Defekte Testfälle können nicht stillschweigend zu Produktfehlern werden.
- Läufe sind versioniert und auf Reproduzierbarkeit ausgelegt.
- Baseline `golden-2026-09-25` hat 40 synthetische deutsche Kündigungsfälle über vier Routen gemessen; die Ergebnisse stehen auf den Seiten 13–14.

✗ Belegt nicht

- Dass ARAMs Ergebnisse rechtlich richtig oder regelkonform sind oder anwaltlicher Arbeit gleichkommen.
- Wie echte Prüfpersonen abschneiden: Es gibt keine L5-B-Studie.
- Einsatzreife ohne menschliches Review. Mit 2,5 % striktem Ende-zu-Ende-Erfolg und 63,0 % Durchschlupf kritischer Fehler stützt diese Baseline das **nicht**.
- Leistung bei realen, nicht synthetischen Fällen oder bei Routen außerhalb des Datensatzes.
- Eine Entwicklung über die Zeit: Dies ist die erste Baseline.

Zweck des Evaluation- & Test-Harness ist nicht bloß eine Punktzahl. Er schafft reproduzierbare Nachweise darüber, was geprüft wurde, was ARAM tatsächlich getan hat, wie das im Vergleich zu einem unabhängigen Erwartungsergebnis ausfiel, wo Fehler ihren Ursprung hatten und ob eine Behebung dauerhaft geschützt bleibt.

Kennzahlenkatalog mit Baseline-Werten

Alle 28 Katalogkennzahlen und die L5-A-Diagnose, mit Zähler/Nenner-Definition aus der Kennzahlenreferenz und dem Wert aus Baseline golden-2026-09-25 . Unter dem deutschen Namen stehen der englische Originalname und die Report-ID.

#	EBENE	KENNZAHL	ZÄHLER / NENNER	WERT	
1	L0	Wiederherstellung kritischer Textstellen Critical Text Recovery Rate l0.critical_text_recovery_rate	correctly_recovered_critical_spans / expected_critical_spans	100,0 %	
2	L0	Genauigkeit kritischer Werte Critical Value Accuracy l0.critical_value_accuracy	correct_critical_values / expected_critical_values	100,0 %	
3	L0	Seitenwiederherstellung & -zuordnung Page Recovery & Association Accuracy l0.page_recovery_association_accuracy	correct_page_associations / expected_page_associations	100,0 %	
4	L0	Genauigkeit des Wiederherstellungspfads Recovery Path Accuracy l0.recovery_path_accuracy	correct_recovery_paths / recovery_path_cases	100,0 %	
5	L0	Rate unsicherer Fortsetzung ↓ Unsafe Continuation Rate l0.unsafe_continuation_rate	unsafe_continuations / fail_closed_opportunities	—	nicht berechnet:
6	L1	Klassifikationsgenauigkeit Classification Accuracy l1.classification_accuracy	correct_predictions / eligible_classifiable_documents	59,2 %	
7	L1	Rate falsch-sicherer Klassifikation ↓ Wrong-Confident Classification Rate l1.wrong_confident_classification_rate	wrong_high_confidence_predictions / high_confidence_predictions	21,2 %	
8	L1	Rate falschen Regelpaket-Routings ↓ Wrong Rule-Pack Routing Rate l1.wrong_rule_pack_routing_rate	wrong_routed_documents / documents_entering_routing_boundary	39,5 %	
9	L1	Korrekte Enthaltung / Mehrdeutigkeit Correct Abstention / Ambiguity Rate l1.correct_abstention_ambiguity_rate	correct_abstentions_or_flags / gold_ambiguity_cases	46,8 %	
10	L1	Präzision & Recall je Dokumenttyp Per-Type Precision & Recall l1.per_type_precision_recall	per document type (no single ratio)	—	je T
11	L2	Fakten-Recall Fact Recall l2.fact_recall	matched_expected_candidates / expected_extractable_candidates	42,9 %	
12	L2	Fakten-Präzision Fact Precision l2.fact_precision	matched_actual_candidates / scored_actual_candidates	55,1 %	
13	L2	Wertgenauigkeit Value Accuracy l2.value_accuracy	value_correct_matched_candidates / matched_candidate_pairs	100,0 %	
14	L2	Rate sicherer Regel-Enthaltung Safe Rule Abstention Rate l2.safe_rule_abstention_rate	safe_abstentions / must_abstain_opportunities	99,7 %	
15	L2	Belegrückverfolgbarkeit der Kandidaten Candidate Evidence Traceability Rate l2.candidate_evidence_traceability_rate	candidates_with_valid_trace / candidates_requiring_provenance	88,7 %	

#	EBENE	KENNZAHL	ZÄHLER / NENNER	WERT	
16	L3	Genauigkeit der Feldzuordnung Field Mapping Accuracy l3.field_mapping_accuracy	correct_field_mappings / expected_mappable_facts	94,8 %	
17	L3	Erhalt bestätigter Fakten Confirmed-Fact Preservation Rate l3.confirmed_fact_preservation_rate	preserved_confirmed_facts / confirmed_facts_in_scope	84,0 %	
18	L3	Genauigkeit abgeleiteter Felder Derived-Field Accuracy l3.derived_field_accuracy	correct_expected_derivations / expected_derivations	—	nicht berechnet:
19	L3	Vollständigkeit der Transformation Transformation Completeness l3.transformation_completeness	required_targets_present / expected_transformable_targets	94,8 %	
20	L3	Konflikt- & Herkunftssicherheit Conflict & Provenance Safety l3.conflict_provenance_safety	passed_conflict_and_provenance_assertions / applicable_safety_assertions	100,0 %	
21	L4	Schema-Bestehensrate Schema Pass Rate l4.schema_pass_rate	schema_valid_cases / cases_validated	82,5 %	
22	L4	Vollständigkeit der Pflichtfelder Required-Field Completeness l4.required_field_completeness	valid_required_fields_present / applicable_required_fields	100,0 %	
23	L4	Invarianten-Bestehensrate Invariant Pass Rate l4.invariant_pass_rate	passed_invariant_assertions / executed_invariant_assertions	—	nicht berechnet:
24	L4	Gültigkeit der Beweisstatus Evidence-State Validity l4.evidence_state_validity	valid_evidence_state_assertions / applicable_evidence_state_assertions	100,0 %	
25	L5	Rate strikt verifizierter Fälle Verified Case Pass Rate l5.verified_case_pass_rate	strict_verified_case_passes / evaluated_cases	2,5 %	
26	L5	Genauigkeit kritischer Felder Critical Field Accuracy l5.critical_field_accuracy	correct_final_tier1_fields / applicable_tier1_fields	63,9 %	
27	L5	Durchschlupfrate kritischer Fehler ↓ Critical Error Escape Rate l5.critical_error_escape_rate	machine_critical_errors_still_wrong_or_unresolved_at_exit / machine_critical_errors_present_at_review_entry	63,0 %	
28	L5	Menschlicher Korrekturaufwand ↓ Human Correction Burden l5.human_correction_burden	(corrected_machine_suggestions + manual_field_entries + manually_resolved_conflicts) / reviewed_fields	—	nicht berechnet:
D1	L5	Aktionsaufwand im geskripteten Review Scripted Review Action Burden (diagnostic) l5a.scripted_review_action_burden	L5-A diagnostic only; must not use the Human Correction Burden metric id	17,3 %	

Namenshinweis für das Engineering

Das übergeordnete README und die Layer-READMEs verwenden für fünf Kennzahlen neuere Namen. Dieses Dokument nutzt die Namen der Kennzahlenreferenz, weil sie mit den IDs im Baseline-Bericht übereinstimmen.

#	KENNZAHLENREFERENZ / BERICHT	NEUERER README-NAME
7	Wrong-Confident Classification Rate	Unsafe High-Score Classification Rate
8	Wrong Rule-Pack Routing Rate	Classification-Caused Wrong Routing Rate (+ Routing Registry Error Rate)

#	KENNZAHLENREFERENZ / BERICHT	NEUERER README-NAME
9	Correct Abstention / Ambiguity Rate	Safe Uncertainty Handling Rate
17	Confirmed-Fact Preservation Rate	Verified-Fact Preservation Rate
20	Conflict & Provenance Safety	Transformation Safety & Lineage

Quellen: Case_Intake_Evals_and_Testing_harness/Evals
Implementation/TAURI_INTAKE_EVAL_METRICS_REFERENCE.md ,
Evals_Illustrative_docs/metrics_golden-2026-09-25.md

Bewertungsstatus

Jede ausgewertete Zeile hat genau einen Status. Nur `SCORED`-Zeilen fließen in die
Nenner der Produktkennzahlen ein.

STATUS	BEDEUTUNG	WIRKUNG AUF PRODUKTKENNZAHLEN
SCORED	Regulär ausgewertet	Zählt
NOT_APPLICABLE	Kennzahl trifft auf diese Zeile nicht zu; ein Nenner von null ergibt null	Wird als „—“ gezeigt, nie als 0 oder 100 %
NOT_SCORED_EXECUTION_ERROR	Harness oder Produkt ließ sich nicht ausführen (z. B. <code>TAURI_START_FAILED</code>)	Ausgenommen; Infrastruktur-Job scheitert
NOT_SCORED_CONTRACT_ERROR	Abweichung von Evaluations- oder Kompatibilitätsvertrag (z. B. <code>SUT_COMPATIBILITY_MISMATCH</code>)	Ausgenommen; an Vertragsverantwortliche
NOT_SCORED_FIXTURE_DEFECT	Der Testfall selbst ist defekt (z. B. <code>FIXTURE_ORACLE_HASH_MISMATCH</code>)	Ausgenommen; Testfall in Quarantäne

Taxonomie nicht produktbezogener Defekte: `FIXTURE_DEFECT` ,
`EVALUATION_CONTRACT_ERROR` , `CHECKPOINT_CONTRACT_ERROR` ,
`HARNESS_EXECUTION_ERROR` .

Quellen: `Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVALUATION_HARNESS_DESIGN.md` §3,
`Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVAL_METRICS_REFERENCE.md` ,
`Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVAL_REGRESSION_CI_DESIGN.md` §7, §12

Fixture-Gates, Freigabe und Unabhängigkeit

Was ein Testfall bestehen muss, bevor er ARAM bewerten darf.

GATE	GATE	PRÜFUNGEN
G0	Vertragsbindung	Evaluationsvertrag auflösbar und Hash stimmt; SUT-Kompatibilitätsvertrag auflösbar; ein Owner je Namespace; Erklärung zur Oracle-Unabhängigkeit besteht.
G1	Integrität der Fixture-Spezifikation	Schema/Constraints bestehen; Tier-1-Autorität gültig; IDs eindeutig und deterministisch; Fakten-, Beleg- und Reviewstatus stimmig.
G2	Quell- / Build-Integrität	Erforderliche Assertions exakt eingebracht; keine undeklarierten kritischen Werte; aufbewahrte Quelle entspricht der gerenderten Eingabe.
G3	Integrität der gerenderten Belege	Erforderliche Belege vorhanden; Artefakt-Hash/Seite/Span/Slot auflösbar; gerendeter Wert entspricht der deklarierten Assertion.
G4	Mutationsintegrität	Mutationsklasse/-rezept deklariert; Ankertransformationen explizit; semantische und Belegwirkung wie deklariert.
G5	Oracle-Integrität	Kandidatenabgleich auflösbar; Oracle unabhängig kompiliert; menschlich zu klärende Punkte nicht geraten; ausreichende Wahrheit für die Zielkennzahl.
G6	Isolation / Replay / Paket	Verdeckter Lösungsschlüssel für das SUT nicht sichtbar; Reproduzierbarkeitsvertrag besteht; Paket vollständig und hash-konsistent.

Unabhängigkeitsregeln

- Keine Fixture-/Oracle-Komponente darf die produktive Implementierung des bewerteten Verhaltens importieren, aufrufen, deren Ausgaben kopieren oder wiederverwenden. Geteilte Primitive sind nur zulässig, wenn sie dieses Verhalten nicht abbilden.
- Der Oracle-Compiler nutzt nur Vertrag, eingefrorene `fixture_spec.yaml`, Renderer-Anker, Mutationsherkunft und menschlich freigegebene Klärungen, niemals Vorhersagen von Tauri.
- Keine bewertete Tier-1-Tatsache darf allein deshalb akzeptiert werden, weil ein LLM sie erzeugt hat. Zulässige Autorität: `DETERMINISTIC_SYNTHETIC`, `HUMAN_APPROVED_SYNTHETIC` oder `HUMAN_RESOLUTION_REQUIRED`.
- Tier-2/3-Material darf nur stichprobenartig geprüft werden, wenn es nicht bewertet wird.

Quellen: `Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/EVALS_DATASET_AND_GROUND_TRUTH_DESIGN.md` §16, §18, §20–22;
`Case_Intake_Evals_and_Testing_harness/TAURI_INTAKE_DATASET_AGENT_DESIGN.md`
§7.3, §34, §37, §39, §41–42

Run-Manifest, Replay und Baselines

Was festgehalten wird, damit jedes Ergebnis reproduzierbar ist.

Felder des Run-Manifests

run_id fixture_id fixture_version fixture_spec_hash
evaluation_contract_version evaluation_contract_hash
sut_compatibility_version intake_version eval_mode_version
harness_version mode layer platform injected_oracle_hashes

Bewertete Ergebnisse pinnen zusätzlich:

checkpoint_versions oracle_compiler_version oracle_hashes
candidate_matching_policy_version metric_catalog_version
comparator_policy_version scoring_status

Replay-Modi

- `BYTE_REPLAYABLE` — alle wiederholten Artefakt-Hashes entsprechen den Manifest-Hashes
- `SEMANTICALLY_REPLAYABLE` — Byte-Identität nicht garantiert, aber Spec-Hash, Assertion-/Kandidatenmenge, semantische Herkunft und Oracle-Werte müssen übereinstimmen
- `FROZEN_ONLY` — freigegebene Artefakte werden nie neu erzeugt; gespeicherte Hashes müssen dem eingefrorenen Manifest entsprechen

Ein Replay erzeugt eine neue Run-ID und verweist per `replay_of` auf das Original.

Run-Modi

- `isolated` — eine Ebene mit injizierter, bekannt richtiger Eingabe
- `end_to_end` — gesamter Ablauf, ohne Injektion
- `scripted_review` — L5-A: deterministisches Review-Skript
- `interactive_review` — L5-B: Telemetrie echter Prüfpersonen nach festgelegtem Protokoll

Felder des Baseline-Vergleichs

new_failures fixed_failures persistent_failures fixture_defects contract_errors metric_deltas

Eine Baseline ist ein bewertetetes Ergebnis über einen eingefrorenen Datensatz mit festgelegter Bewertungssemantik. Sie pinnt Version des Regressionsdatensatzes, Fixture-/Oracle-Hashes, Version/Hash des Evaluationsvertrags, Version des Kandidatenabgleichs, des Kennzahlenkatalogs und des Comparators sowie die Intake-Version.

Quellen: `Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_TEST_HARNESS_DESIGN.md` §3, §5, §8, §10;
`Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVALS_L0_L5_IMPLEMENTATION_DESIGN.md` §14;
`Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVAL_REGRESSION_CI_DESIGN.md` §3, §9

Fehler- und Ursachentaxonomie

Wie Fehler benannt und ihr Ursprung festgehalten wird.

Produktfehlerfamilien

- RECOVERY_FAILURE
- CLASSIFICATION_FAILURE
- WRONG_CONFIDENT_CLASSIFICATION
- WRONG_RULE_PACK
- EXTRACTION_MISS
- EXTRACTION_SPURIOUS
- VALUE_ERROR
- PROVENANCE_ERROR
- MAPPING_ERROR
- DERIVATION_ERROR
- CONFLICT_HANDLING_ERROR
- SCHEMA_ERROR
- INVARIANT_ERROR
- HUMAN_REVIEW_ESCAPE

Ende-zu-Ende-Fehlertypen (L5)

- FINAL_CASE_VALUE_ERROR
- FINAL_CASE_STATE_ERROR
- CRITICAL_CONFLICT_LOST
- HUMAN_REVIEW_ESCAPE
- REVIEW_TRIGGER_ERROR
- FINAL_EXPORT_ERROR

Nicht produktbezogene Defekte

- FIXTURE_DEFECT
- EVALUATION_CONTRACT_ERROR
- CHECKPOINT_CONTRACT_ERROR
- HARNESS_EXECUTION_ERROR

Nicht bewertbaren Testfällen werden keine Produkt-Ursachenebenen zugewiesen.

L5-Eindämmungsdatensatz


- origin_layer
- origin_component
- first_detection_opportunity
- detection_layer
- detection_component
- expected_containment_layer
- expected_containment_action
- actual_containment_layer
- actual_containment_action
- escape_boundary
- final_impact

Ursache = die **früheste kausal hinreichende Abweichung**, ermittelt entlang expliziter Herkunftsketten. Kausalität wird nicht allein aus der Reihenfolge der Ebenen abgeleitet. Mitursachen werden getrennt gespeichert. Auf L5 genügt eine einzelne `root_cause_layer` nicht: Ursprung, erste Erkennungsgelegenheit, erwartete und tatsächliche Eindämmung sowie die Durchschlupfgrenze werden erfasst.

Quellen: `Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVALS_L0_L5_IMPLEMENTATION_DESIGN.md` §9, §11;
`Case_Intake_Evals_and_Testing_harness/Evals`
`Implementation/TAURI_INTAKE_EVALUATION_HARNESS_DESIGN.md` §12–14

Ergebnisse je Testfall (40 Testfälle)

Jede Zelle ist der gepoolte Prozentwert eines Testfalls für eine Kennzahl
(Spaltennummern wie in Anhang A). Dunkler = höherer Prozentwert. Bei ↓-Spalten ist höher schlechter. Schraffiert = nicht berechnet. Hervorgehoben ist CASE-GD-06824 .



Als Tabelle anzeigen

TESTFALL	1	2	3	4	6	7↓	8↓	9	11	12	13	14	15	16	17	19	20	21	22	24	25	
GA-24819	100,0	100,0	100,0	100,0	100,0	20,0	20,0	0,0	83,3	55,6	100,0	87,5	100,0	100,0	83,3	100,0	100,0	100,0	100,0	100,0	100,0	1
GA-25614	100,0	100,0	100,0	100,0	71,4	0,0	28,6	—	45,5	71,4	100,0	100,0	100,0	100,0	81,8	100,0	100,0	100,0	100,0	100,0	0,0	
GA-28388	100,0	100,0	100,0	100,0	71,4	16,7	37,5	0,0	44,4	44,4	100,0	92,9	80,0	100,0	77,8	100,0	100,0	100,0	100,0	100,0	0,0	
GA-54310	100,0	100,0	100,0	100,0	60,0	25,0	37,5	66,7	66,7	75,0	100,0	100,0	85,7	100,0	88,9	100,0	100,0	100,0	100,0	100,0	0,0	

TESTFALL	1	2	3	4	6	7	8	9	11	12	13	14	15	16	17	19	20	21	22	24	25
GA-60900	100,0	100,0	100,0	100,0	60,0	40,0	44,4	50,0	55,6	71,4	100,0	100,0	83,3	100,0	88,9	100,0	100,0	100,0	100,0	100,0	0,0
GB-01515	100,0	100,0	100,0	100,0	70,0	30,0	27,3	0,0	33,3	57,1	100,0	100,0	100,0	100,0	83,3	100,0	100,0	100,0	100,0	100,0	0,0
GB-17824	100,0	100,0	100,0	100,0	60,0	40,0	42,9	50,0	50,0	71,4	100,0	100,0	83,3	100,0	90,0	100,0	100,0	100,0	100,0	100,0	0,0
GB-42618	100,0	100,0	100,0	100,0	70,0	41,7	30,8	0,0	58,3	63,6	100,0	100,0	87,5	100,0	83,3	100,0	100,0	100,0	100,0	100,0	0,0
GC-01522	100,0	100,0	100,0	100,0	75,0	18,2	20,0	66,7	46,2	54,5	100,0	100,0	100,0	100,0	84,6	100,0	100,0	100,0	100,0	100,0	0,0
GC-15222	100,0	100,0	100,0	100,0	66,7	20,0	26,7	66,7	30,8	57,1	100,0	100,0	100,0	100,0	84,6	100,0	100,0	100,0	100,0	100,0	0,0
GC-15521	100,0	100,0	100,0	100,0	75,0	18,2	20,0	66,7	53,8	53,8	100,0	100,0	87,5	100,0	84,6	100,0	100,0	100,0	100,0	100,0	0,0
GC-15722	100,0	100,0	100,0	100,0	66,7	33,3	40,0	0,0	46,2	66,7	100,0	100,0	100,0	100,0	84,6	100,0	100,0	100,0	100,0	100,0	0,0
GC-27616	100,0	100,0	100,0	100,0	72,7	33,3	35,7	0,0	58,3	63,6	100,0	100,0	100,0	100,0	83,3	100,0	100,0	100,0	100,0	100,0	0,0
GC-35211	100,0	100,0	100,0	100,0	71,4	16,7	30,0	66,7	75,0	60,0	100,0	100,0	100,0	100,0	50,0	100,0	100,0	100,0	100,0	100,0	0,0
GC-37111	100,0	100,0	100,0	100,0	75,0	18,2	20,0	66,7	53,8	53,8	100,0	100,0	87,5	100,0	84,6	100,0	100,0	0,0	100,0	100,0	0,0
GD-01325	100,0	100,0	100,0	100,0	55,6	0,0	44,4	—	30,0	33,3	100,0	100,0	100,0	85,7	80,0	85,7	100,0	100,0	100,0	100,0	0,0
GD-01723	100,0	100,0	100,0	100,0	54,5	25,0	46,2	50,0	40,0	46,2	100,0	100,0	75,0	87,5	86,7	87,5	100,0	100,0	100,0	100,0	0,0
GD-01923	100,0	100,0	100,0	100,0	57,1	0,0	42,9	—	50,0	66,7	100,0	100,0	100,0	87,5	83,3	87,5	100,0	100,0	100,0	100,0	0,0
GD-03712	100,0	100,0	100,0	100,0	50,0	0,0	50,0	—	36,4	57,1	100,0	100,0	100,0	85,7	81,8	85,7	100,0	100,0	100,0	100,0	0,0
GD-05525	100,0	100,0	100,0	100,0	57,1	0,0	42,9	—	36,4	50,0	100,0	100,0	80,0	87,5	81,8	87,5	100,0	100,0	100,0	100,0	0,0
GD-06824	100,0	100,0	100,0	100,0	41,7	37,5	50,0	50,0	42,9	54,5	100,0	100,0	75,0	87,5	85,7	87,5	100,0	100,0	100,0	100,0	0,0
GD-20611	100,0	100,0	100,0	100,0	33,3	33,3	66,7	—	33,3	75,0	100,0	100,0	75,0	85,7	88,9	85,7	100,0	100,0	100,0	100,0	0,0
GD-23407	100,0	100,0	100,0	100,0	50,0	0,0	50,0	—	50,0	75,0	100,0	100,0	75,0	100,0	100,0	100,0	100,0	100,0	100,0	100,0	0,0
GD-23518	100,0	100,0	100,0	100,0	44,4	20,0	45,5	100,0	50,0	60,0	100,0	100,0	85,7	87,5	83,3	87,5	100,0	100,0	100,0	100,0	0,0
GD-27312	100,0	100,0	100,0	100,0	60,0	0,0	40,0	—	33,3	42,9	100,0	100,0	75,0	85,7	88,9	85,7	100,0	100,0	100,0	100,0	0,0
GD-28210	100,0	100,0	100,0	100,0	71,4	0,0	28,6	—	41,7	55,6	100,0	100,0	83,3	100,0	83,3	100,0	100,0	0,0	100,0	100,0	0,0
GD-28410	100,0	100,0	100,0	100,0	50,0	0,0	50,0	—	20,0	33,3	100,0	100,0	100,0	85,7	80,0	85,7	100,0	100,0	100,0	100,0	0,0
GD-29622	100,0	100,0	100,0	100,0	46,2	40,0	53,3	0,0	42,9	54,5	100,0	100,0	85,7	100,0	85,7	100,0	100,0	0,0	100,0	100,0	0,0
GD-29722	100,0	100,0	100,0	100,0	50,0	20,0	50,0	—	30,0	42,9	100,0	100,0	75,0	100,0	80,0	100,0	100,0	0,0	100,0	100,0	0,0
GD-39515	100,0	100,0	100,0	100,0	50,0	16,7	50,0	—	33,3	55,6	100,0	100,0	83,3	87,5	86,7	87,5	100,0	100,0	100,0	100,0	0,0
GD-48321	100,0	100,0	100,0	100,0	57,1	0,0	42,9	—	54,5	60,0	100,0	100,0	85,7	100,0	81,8	100,0	100,0	0,0	100,0	100,0	0,0
GD-49511	100,0	100,0	100,0	100,0	50,0	20,0	50,0	—	45,5	62,5	100,0	100,0	100,0	100,0	90,9	100,0	100,0	100,0	100,0	100,0	0,0
GD-54109	100,0	100,0	100,0	100,0	54,5	14,3	41,7	100,0	40,0	46,2	100,0	100,0	85,7	87,5	86,7	87,5	100,0	100,0	100,0	100,0	0,0
GD-54612	100,0	100,0	100,0	100,0	57,1	0,0	42,9	—	27,3	50,0	100,0	100,0	100,0	85,7	81,8	85,7	100,0	100,0	100,0	100,0	0,0
GD-57019	100,0	100,0	100,0	100,0	42,9	25,0	57,1	—	44,4	50,0	100,0	100,0	100,0	83,3	77,8	83,3	100,0	100,0	100,0	100,0	0,0
GD-60307	100,0	100,0	100,0	100,0	55,6	16,7	44,4	—	38,5	55,6	100,0	100,0	100,0	100,0	84,6	100,0	100,0	0,0	100,0	100,0	0,0
GD-67819	100,0	100,0	100,0	100,0	62,5	16,7	37,5	—	20,0	33,3	100,0	100,0	100,0	100,0	80,0	100,0	100,0	100,0	100,0	100,0	0,0
GD-73613	100,0	100,0	100,0	100,0	50,0	25,0	50,0	—	42,9	50,0	100,0	100,0	100,0	100,0	71,4	100,0	100,0	100,0	100,0	100,0	0,0
GD-82509	100,0	100,0	100,0	100,0	42,9	25,0	44,4	100,0	37,5	50,0	100,0	100,0	100,0	85,7	87,5	85,7	100,0	100,0	100,0	100,0	0,0
GD-95511	100,0	100,0	100,0	100,0	50,0	16,7	50,0	—	35,7	45,5	100,0	100,0	71,4	100,0	85,7	100,0	100,0	0,0	100,0	100,0	0,0

Glossar: Fachbegriff → verständliche Formulierung

Zuerst die Formulierung für Kundinnen und Kunden; der Fachbegriff ist das, was in Logs, Berichten und im Repository steht.

FACHBEGRIFF	VERSTÄNDLICHE FORMULIERUNG
fixture	kontrollierter Testfall
fixture_spec.yaml	maßgebliche Testfalldefinition
oracle	unabhängig abgeleitetes Erwartungsergebnis (Lösungsschlüssel)
SUT	ARAM Intake als geprüftes System
sut_visible	die einzigen Dateien, die ARAM sehen darf
Test Harness	System, das den kontrollierten Test ausführt und protokolliert
Evaluation Harness	System, das das Ergebnis unabhängig abgleicht und bewertet
checkpoint	festgehaltenes Ergebnis einer bestimmten Verarbeitungsstufe
provenance	Rückverfolgung zum stützenden Beleg
abstention	begründete Enthaltung statt unbelegter Festlegung
invariant	Bedingung, die für einen gültigen Fall immer gelten muss
Tier -1	Tatsache, deren Fehler Route, Gate, Frist oder Fallrichtigkeit ändern kann
H1	menschliche Prüfung jedes vorgeschlagenen Werts
L5-A	geskriptetes Ende-zu-Ende-Regressionsreview
L5-B	Studie mit echten Prüfpersonen
NOT_SCORED_FIXTURE_DEFECT	Testfalldefekt: von der Produktbewertung ausgenommen
NO_ELIGIBLE_UNITS	in diesem Lauf nichts zu messen: als „—“ dargestellt
baseline	bewertetes Ergebnis über einen eingefrorenen Datensatz mit festgelegten Bewertungsregeln

ARAM Intake · Evaluation & Test-Harness · Kennzahlen: Baseline `golden-2026-09-25` (Evals_Illustrative_docs/metrics_golden-2026-09-25.md). Sämtliches Fallmaterial ist synthetisch: keine reale Person, kein realer Fall. Dieses Dokument beschreibt geprüftes Systemverhalten. Es trifft keine Aussage über rechtliche Richtigkeit und ist keine Rechtsberatung.